1 Exercici

Out[2]:

Out[3]:

Descarrega el data set Airlines Delay: Airline on-time statistics and delay causes (https://www.kaggle.com/giovamata/airlinedelaycauses) i carrega'l a un pandas Dataframe. Explora les dades que conté, i queda't únicament amb les columnes que consideris rellevants.

```
In [1]: import os, datetime
import pandas as pd
import numpy as np

import warnings
warnings.simplefilter(action='ignore', category=FutureWarning)
executed in 410ms, finished 10:12:15 2021-04-14

In [2]: rows = None
pd.options.display.max_columns = None

datasets_path = r"D:\Oscar\FORMACIO\DIGITAL\DATA SCIENCE with Python\Datasets"
datasets_path = os.getcwd()
datasets_path += os.sep

file = datasets_path + "DelayedFlights.csv"
df = pd.read_csv(file, sep=',', encoding='utf8', index_col=0, nrows=rows)
df.head(3)
executed in 9.01s, finished 10:06:53 2021-04-14
```

:	,	Year	Month	DayofMonth	DayOfWeek	DepTime	CRSDepTime	ArrTime	CRSArrTime	UniqueCarrier	FlightNum	TailNum	ActualElapsedTime	CRSElapsedTime	AirTime	ArrDelay
	0	2008	1	;	3 4	2003.0	1955	2211.0	2225	WN	335	N712SW	128.0	150.0	116.0	-1
	1	2008	1	;	3 4	754.0	735	1002.0	1000	WN	3231	N772SW	128.0	145.0	113.0	
	2	2008	1	;	3 4	628.0	620	804.0	750	WN	448	N428WN	96.0	90.0	76.0	1

Documentació de la descripció de les columnes a Get the data (http://stat-computing.org/dataexpo/2009/the-data.html)

Variable descriptions

	Name	Description
1	Year	1987-2008
2	Month	1-12
3	DayofMonth	1-31
4	DayOfWeek	1 (Monday) - 7 (Sunday)
5	DepTime	actual departure time (local, hhmm)
6	CRSDepTime	scheduled departure time (local, hhmm)
7	ArrTime	actual arrival time (local, hhmm)
8	CRSArrTime	scheduled arrival time (local, hhmm)
9	UniqueCarrier	unique carrier code
10	FlightNum	flight number
11	TailNum	plane tail number
12	ActualElapsedTime	in minutes
13	CRSElapsedTime	in minutes
14	AirTime	in minutes
15	ArrDelay	arrival delay, in minutes
16	DepDelay	departure delay, in minutes
17	Origin	origin IATA airport code
18	Dest	destination <u>IATA airport code</u>
19	Distance	in miles
20	Taxiln	taxi in time, in minutes
21	TaxiOut	taxi out time in minutes
22	Cancelled	was the flight cancelled?
23	CancellationCode	reason for cancellation (A = carrier, B = weather, C = NAS, D = security)
24	Diverted	1 = yes, 0 = no
25	CarrierDelay	in minutes
26	WeatherDelay	in minutes
27	NASDelay	in minutes
28	SecurityDelay	in minutes
29	LateAircraftDelay	in minutes

:		ANY	MES	DIA	DIA_SET	COD_AEROLINIA	DURADA_TOTAL	DURADA_AIRE	RETARD	COD_ORIGEN	COD_DESTI	DISTANCIA	CANCELAT	COD_CANCELACIO	DESVIAT	
	3981018	2008	7	7 15	5 2	2 FL	177.0	160.0	11.0	SJU	MCO	1189	0	1	N (0
	2323551	2008	4	1 26	6	S AS	188.0	164.0	-7.0	SEA	ANC	1449	0	1	N (0
	3517912	2008	6	3 13	3 5	5 AA	51.0	39.0	-3.0	MIA	TPA	204	0	1	N (0

```
In [4]: #convertirem int64 i float64 a int32 i float32 per reduir el dataframe #definim una funcio que genera el diccionari de conversió de tipus
          #definum una functo que genera el diccionari de conversio de tipi
def dic_convert(colsint, colsifloat):
    dtype_l = []
    for i in range(0, len(colsint)): dtype_l.append("int32")
    for i in range(0, len(colsifloat)): dtype_l.append("float32")
    return dict(zip(colsint+colsfloat, dtype_l))
          df.info(memory_usage="deep")
           executed in 1.68s, finished 10:06:59 2021-04-14
           <class 'pandas.core.frame.DataFrame'>
Int64Index: 1936758 entries, 0 to 7009727
Data columns (total 14 columns):
                Column
-----
                                      Dtype
                                       int32
                 MES
                                      int32
                  DIA
                                       int32
                 DIA_SET
COD_AEROLINIA
                                      object
                 DURADA_TOTAL
DURADA_AIRE
                                       float32
                                       float32
float32
                  RETARD
                 COD_ORIGEN
                                       object
            9 COD_DESTI
10 DISTANCIA
11 CANCELAT
                                       object
int32
                                       int32
                 COD CANCELACIO object
            12
           13 DESVIAT int32
dtypes: float32(3), int32(7), object(4)
memory usage: 526.4 MB
           2 Exercici
           Fes un informe complet del data set:.
           2.1 Resumeix estadísticament les columnes d'interès
In [5]: df[["DURADA_TOTAL", "DURADA_AIRE", "DISTANCIA"]].describe()
           executed in 341ms, finished 10:07:01 2021-04-14
Out[5]:
                   DURADA_TOTAL DURADA_AIRE DISTANCIA
                       1.928371e+06 1.928371e+06 1.936758e+06
            count
                      1.333069e+02 1.082788e+02 7.656862e+02
              std
                      7.200964e+01 6.860229e+01 5.744797e+02
              min
                         1.400000e+01 0.000000e+00 1.100000e+01
              25%
                         8.000000e+01
                                            5.800000e+01 3.380000e+02
                         1.160000e+02
              50%
                                            9.000000e+01 6.060000e+02
             75%
                         1.650000e+02
                                            1.370000e+02 9.980000e+02
                         1.114000e+03 1.091000e+03 4.962000e+03
             max
In [6]: #podem veure, en concret, el promig de duració en l'aire d'un vol
          minuts = df["DURADA_AIRE"].mean()
           min to strtime(minuts)
           executed in 24ms, finished 10:07:02 2021-04-14
Out[6]: '1h:48m:16s'
return round(km, 2)
                    df["DISTANCIA"].mean()
           str(miles_to_km(dist)) + "km
           executed in 17ms, finished 10:07:03 2021-04-14
Out[7]: '1232.25km'
In [8]: #per exemple podem veure els vols per dia de la setmana
#abans podem mapejar la columna DIA_SET per ferla més llegible
dies_dict = {1:"diumenge", 2:"dilluns", 3:"dimarts", 4:"dimecres", 5:"dijous", 6:"divendres", 7:"dissabte"}
df["DIA_SET"] = df["DIA_SET"].map(dies_dict)
           vols_dia = df.DIA_SET.value_counts()
vols_dia
           executed in 448ms, finished 10:07:05 2021-04-14
Out[8]: dijous
                            323259
           diumenge
dimecres
                            290933
289451
```

dissabte

dimarts dilluns

divendres

286111

262805 260943 223256

Name: DIA_SET, dtype: int64

```
In [9]: #en percentatges els vols per dia de la setmana:
totals = len(df.DIA_SET)
vols_dia.apply(lambda x : str(round((x*100/totals), 2)) + "%")
              executed in 11ms, finished 10:07:05 2021-04-14
  Out[9]: dijous
             diumenge
                                15.02%
                                14.95%
14.77%
13.57%
             dimecres
dissabte
              dimarts
              dilluns
                                13.47%
             divendres 11.53%
Name: DIA_SET, dtype: object
In [10]: #analitzarem els vols cancel·lats i desviats
#convertim CANCELAT i DESVIAT a boolean per visualitzar
df = df.astype({"CANCELAT": bool, "DESVIAT": bool})
             #definim funcio per retornar porcentatges de Series de tipus boolean
             def perc_trues(series):
try: trues = series.value_counts()[True]
except: trues = 0
                   totals = len(series)
return str(round((trues * 100 / totals), 2)) + "%"
              executed in 271ms, finished 10:07:08 2021-04-14
In [11]: #observem el nombre de vols cancel·lats
df.CANCELAT.value_counts()
             executed in 52ms, finished 10:07:09 2021-04-14
Out[11]: False
                      1936125
             True 633
Name: CANCELAT, dtype: int64
In [12]: #percentatge de vols totals cancel·lats
    perc_trues(df["CANCELAT"])
             executed in 50ms, finished 10:07:10 2021-04-14
Out[12]: '0.03%'
In [13]: #calcularem dels cancel·lats els percentatges dels motius
             df["COD_CANCELACIO"].value_counts()
              executed in 281ms, finished 10:07:11 2021-04-14
Out[13]: N
                          307
                          246
             C 80
Name: COD_CANCELACIO, dtype: int64
In [14]: #calculem percentatges
             #mopeign els motius per fer-Los entendibles:
motiu_cancel = {"A": "Aerolinia", "B": "Pel temps", "C": "Problema tècnic", "D": "Per seguretat", "N": "No cancelat"}
df["COD_CANCELACIO"] = df["COD_CANCELACIO"].map(motiu_cancel)
             #generem un nou dataframe de cancel·lats:
cancel_df = df[df["CANCELAT"]]
             motius_s = cancel_df["COD_CANCELACIO"].value_counts()
num_cancels = cancel_df["COD_CANCELACIO"].size
              round(100 * motius_s / num_cancels, 2).astype(str) + "%"
              executed in 1.35s, finished 10:07:13 2021-04-14
Out[14]: Pel temps
              Aerolínia
                                         38.86%
             Problema tècnic 12.64%
Name: COD_CANCELACIO, dtype: object
In [15]: #vols desviats
df["DESVIAT"].value_counts()
              executed in 52ms, finished 10:07:14 2021-04-14
Out[15]: False 1929004
             True 7754
Name: DESVIAT, dtype: int64
In [16]: #percentatge vols desviats
             perc_trues(df["DESVIAT"])
              executed in 60ms, finished 10:07:15 2021-04-14
Out[16]: '0.4%'
             #podem veure nombre de vols programats per aerolínia (s'inclouen els cancel·lats)
df.COD_AEROLINIA.value_counts()
In [17]: #podem
             executed in 313ms, finished 10:07:16 2021-04-14
Out[17]: WN
                      377602
             AA
MQ
                      141920
                      141426
             OO
DL
XE
CO
                      132433
114238
                      103663
                      100195
              US
EV
                       98425
81877
             NW
FL
YV
B6
                        79108
                        71284
                        67063
55315
             ОН
                        52657
              9E
AS
F9
                        51885
                        28269
             НΑ
                         7490
             AQ 750
Name: COD_AEROLINIA, dtype: int64
```

```
In [18]: #per exemple podriem visualitzar, per aerolínia, els km totals i km promig de distàncies
vols_x_co = df.groupby('COD_AEROLINIA')

#utilitzem la funció generada anteriorment per visualitzar
vols_x_co["DISTANCIA"].agg([np.sum, np.mean]).applymap(miles_to_km)

executed in 634ms, finished 10:07:18 2021-04-14

Out[18]: sum mean
```

COD_AEROLINIA WN 3.954916e+08 1047.38 AA 3.340938e+08 1741.30 UA 2.457809e+08 1737.88 CO 1.999466e+08 1995.57 DL 1.780624e+08 1558.70 US 1.532836e+08 1557.36 **NW** 1.049296e+08 1326.41 XE 9.993560e+07 964.04 MQ 9.900768e+07 697.63 B6 9.862930e+07 1783.05 **OO** 9.389067e+07 708.97 FL 8.398570e+07 1178.18 EV 6.081013e+07 742.70 AS 5.973907e+07 1520.35 YV 4.396488e+07 655.58 OH 4.349692e+07 826.04 F9 4.081024e+07 1443.64 **9E** 3.878161e+07 747.45 HA 1.085447e+07 1449.19 AQ 1.074078e+06 1432.10

```
In [19]: #o el nombre i percentatge de cancel·lats per aerolínia
def percentatge(series):
    return str(round(series.sum() * 100 / series.count(), 2)) + "%"

vols_x_co["CANCELAT"].agg([np.sum, np.size, percentatge])
executed in 349ms, finished 10:07:19 2021-04:14
```

Out[19]:

			P
COD_AEROLINIA			
AQ	0	750	0.0%
WN	15	377602	0.0%
F9	2	28269	0.01%
FL	7	71284	0.01%
AA	46	191865	0.02%
В6	10	55315	0.02%
DL	21	114238	0.02%
NW	16	79108	0.02%
ОН	12	52657	0.02%
AS	11	39293	0.03%
UA	47	141426	0.03%
us	26	98425	0.03%
co	38	100195	0.04%
EV	29	81877	0.04%
НА	3	7490	0.04%
XE	46	103663	0.04%
MQ	104	141920	0.07%
00	89	132433	0.07%
YV	53	67063	0.08%
9E	58	51885	0.11%

2.2 Troba quantes dades faltants hi ha per columna

```
In [20]: #busquem valors nulls df.isnull().sum() executed in 713ms, finished 10:07:27 2021-04-14
```

```
In [21]: #eliminem els vols cancelats doncs ja no els necessitarem per evaluar les estadistiques dels vols realitzats df.drop(df[df["CANCELAT"]].index, axis="index", inplace = True)
           #eliminem la columna CANCELAT i la de codis doncs no nhi haurà cap
df.drop(['CANCELAT'], axis = 'columns', inplace=True)
df.drop(['COD_CANCELACIO'], axis = 'columns', inplace=True)
            executed in 763ms, finished 10:07:31 2021-04-14
In [22]: #mirem quants vols amb nulls ens queden
df.isnull().any(axis="columns").value_counts()
           executed in 594ms, finished 10:07:32 2021-04-14
Out[22]: False 1928371
           True 7754
dtype: int64
In [23]: #Confirm
           #Confirmem que hi ha el mateix nombre de desviats que de vols amb nulls
df[df["DESVIAT"] == True]["DESVIAT"].value_counts()
           executed in 37ms, finished 10:07:33 2021-04-14
Out[23]: True 7754
Name: DESVIAT, dtype: int64
In [24]: #Concluim que tots els nulls son desviats que no tenen dades del vol
df[df["DESVIAT"] == True].sample()
           executed in 45ms, finished 10:07:34 2021-04-14
Out[24]:
                     ANY MES DIA DIA_SET COD_AEROLINIA DURADA_TOTAL DURADA_AIRE RETARD COD_ORIGEN COD_DESTI DISTANCIA DESVIAT
             6029223 2008 11 30 dissabte
                                                                         WN
                                                                                            NaN
                                                                                                               NaN
                                                                                                                           NaN
                                                                                                                                            OAK
                                                                                                                                                           SAN
                                                                                                                                                                         446
                                                                                                                                                                                      True
In [25]: ##eliminarem els desviats que no ens aporten info, i no ens haurien de quedar nulls al dataframe
df.drop(df[df["DESVIAT"]].index, axis="index", inplace = True)
           #eliminem la columna doncs no nhi haurà cap
df.drop(['DESVIAT'], axis = 'columns', inplace=True)
           #comprovem que no queden valors nulls
df.isnull().any(axis="columns").value_counts()
           executed in 1.39s, finished 10:07:37 2021-04-14
Out[25]: False
                      1928371
            dtype: int64
           2.3 Crea columnes noves (velocitat mitjana del vol, si ha arribat tard o no...)
In [26]: # per crear la velocitat mitjana primer convertirem la distància de milles a km al df
            #utilitzarem la funció miles_to_km(m), generada anterio
            df["DISTANCIA"] = df["DISTANCIA"].apply(miles_to_km)
           df["VEL_MITJA"] = df["DISTANCIA"] / (df["DURADA_AIRE"] / 60)
           #generem la columna booleana si ha arribat tard
df["RETARDAT"] = df["RETARD"].apply(lambda x: True if x>10 else False)
           executed in 4.74s, finished 10:07:43 2021-04-14
Out[26]:
                   ANY MES DIA DIA_SET COD_AEROLINIA DURADA_TOTAL DURADA_AIRE RETARD COD_ORIGEN COD_DESTI DISTANCIA VEL_MITJA RETARDAT
                                                                                                                                                           SFO
             247692 2008
                               1 22 dilluns
                                                                         UA
                                                                                           94.0
                                                                                                              70.0 162.0
                                                                                                                                            BUR
                                                                                                                                                                       524.64 449.691444
                                                                                                                                                                                                        True
                                  10 27 diumenge
                                                                          EV
                                                                                                               85.0
                                                                                                                           19.0
                                                                                                                                             ATL
                                                                                                                                                           MOB
             5693917 2008
                                                                                            105.0
                                                                                                                                                                        486.02
                                                                                                                                                                                  343.072951
                                                                                                                                                                                                        True
             2218183 2008
                                         12 divendres
                                                                         NW
                                                                                            194.0
                                                                                                              173.0
                                                                                                                           18.0
                                                                                                                                                           MCO
                                                                                                                                                                       2108.24
                                                                                                                                                                                                        True
```

<pre>#crearem una columna nova, per expemple, per agrupar les tres columnes de la data en un camp amb el format ddmmaaaa any_s = df["ANY"].astype(str) mes_s = df["MES"].astype(str).str.zfill(2) dia s = df["DIA"].astype(str).str.zfill(2)</pre>									
#esborrem Les columnes DIA, MES i ANY df.drop(columns=["ANY", "MES", "DIA", "DIA_SET"], inplace=True)									
df["DATA"] = dia_s + mes_s + any_s									
df.sample(3)									
executed in 10.7s, finished 10:07:55 2021-04-14									

Out[27]:		COD_AEROLINIA	DURADA_TOTAL	DURADA_AIRE	RETARD	COD_ORIGEN	COD_DESTI	DISTANCIA	VEL_MITJA	RETARDAT	DATA
	801060	00	55.0	27.0	29.0	ASE	DEN	201.17	447.044456	True	23022008
	243335	UA	123.0	88.0	124.0	ORD	PHL	1091.13	743.952257	True	10012008
	1900093	XE	101.0	73.0	23.0	CLE	BDL	764.44	628.306833	True	04042008

2.4 Taula de les aerolínies amb més endarreriments acumulats

Crearem una nova columna amb el nom de l'aerolínia que mapejarem de la base de dades carriers.csv que ens donen a Supplemental data (http://stat-computing.org/dataexpo/2009/supplemental-data.html).

```
In [28]: #importem L'arxiu d'aerolinies com una series, amb els codis d'index
file = datasets_path + "DelayedFlights-carriers.csv"
ap_s = pd.read_csv(file, sep=',', encoding='utf8', index_col=0, squeeze=True)
ap_s.sample(3)
executed in 46ms, finished 10:07:55 2021-04-14
```

Out[28]: Code
SJA San Juan Airlines Inc.
WL World Air Network
GD Transp. Aereos Ejecutivos
Name: Description, dtype: object

```
In [29]: #creem ta nova columna mapejant ta series
df["AEROLINIA"] = df["COD_AEROLINIA"].map(ap_s)
              #eliminem la columna de codi de l'aerolinia
df.drop(columns=["COD_AEROLINIA"], inplace=True)
               df.sample()
               executed in 870ms, finished 10:07:59 2021-04-14
Out[29]:
                   DURADA_TOTAL DURADA_AIRE RETARD COD_ORIGEN COD_DESTI DISTANCIA VEL_MITJA RETARDAT DATA
                                                                                                                                                                                                                AEROLINIA
                                                        60.0 18.0
                                         71.0
                                                                                                     SJC
                                                                                                                          LAS
                                                                                                                                           621.21
                                                                                                                                                             621.21
                                                                                                                                                                                   True 07022008 Southwest Airlines Co.
                622702
In [30]: #agrupem per aerolínia
               vols_x_co = df.groupby('AEROLINIA')
               #obtenim el sumatori dels Trues o el nombre de vols retardats
#(recordem que haviem considerat que era retard si arribava a partir dels 10 min. de l'hora programada)
#(en un futur podríem reconsiderar aquest valor)
               vols_x_co["RETARDAT"].sum()
               executed in 415ms, finished 10:08:00 2021-04-14
Out[30]: AEROLINIA
               AirTran Airways Corporation
Alaska Airlines Inc.
Aloha Airlines Inc.
                                                                                                                                                         52463
                                                                                                                                                        27037
443
144326
               American Airlines Inc.
               American Eagle Airlines Inc.
Atlantic Southeast Airlines
Comair Inc.
Continental Air Lines Inc.
                                                                                                                                                        107440
                                                                                                                                                         62458
42453
                                                                                                                                                         65637
               Continental Air Lines In Delta Air Lines Inc. Expressjet Airlines Inc. Frontier Airlines Inc. Hawaiian Airlines Inc. DetBlue Airways Mesa Airlines Inc. Northwest Airlines Inc.
                                                                                                                                                         80964
78577
                                                                                                                                                          18882
                                                                                                                                                           5293
                                                                                                                                                         41097
55146
60499
               Pinnacle Airlines Inc.
Skywest Airlines Inc.
Southwest Airlines Co.
                                                                                                                                                          38939
98693
                                                                                                                                                        235202
               UN Airways Inc. (Merged with America West 9/05. Reporting for both starting 10/07.)
United Air Lines Inc.
Name: RETARDAT, dtype: int64
                                                                                                                                                         66264
                                                                                                                                                        103644
In [31]: #fem una agregacio per obtindre nombre de retardats, el total de vols per aerolínia i
               #en percentatges els vols retardats per aerolínia
#(utilitzem la funcio percentatge definida anteriorment)
```

	· · · · · ·	0.20	porountargo
AEROLINIA			
Mesa Airlines Inc.	55146	66769	82.59%
Comair Inc.	42453	52453	80.94%
Northwest Airlines Inc.	60499	78843	76.73%
Atlantic Southeast Airlines	62458	81762	76.39%
Expressjet Airlines Inc.	78577	103147	76.18%
American Eagle Airlines Inc.	107440	141223	76.08%
American Airlines Inc.	144326	190910	75.6%
Pinnacle Airlines Inc.	38939	51569	75.51%
Skywest Airlines Inc.	98693	131780	74.89%
JetBlue Airways	41097	54925	74.82%
AirTran Airways Corporation	52463	70969	73.92%
United Air Lines Inc.	103644	140904	73.56%
Delta Air Lines Inc.	80964	113728	71.19%
Hawaiian Airlines Inc.	5293	7472	70.84%
Alaska Airlines Inc.	27037	39010	69.31%
US Airways Inc. (Merged with America West 9/05. Reporting for both starting 10/07.)	66264	98007	67.61%
Frontier Airlines Inc.	18882	28224	66.9%
Continental Air Lines Inc.	65637	99731	65.81%
Southwest Airlines Co.	235202	376201	62.52%
Aloha Airlines Inc.	443	744	59.54%

2.5 Quins són els vols més llargs? I els més endarrerits?

In [32]: #obtindrem, p.ex., els n=5 vols més llargs en quant a durada
#si es repeteixen les durades els mostrem tots
n = 5
df.nlargest(n, "DURADA_TOTAL", keep='all')

executed in 257ms, finished 10:08:04 2021-04-14

Out[32]: DURADA TOTAL DURADA A

:		DURADA_TOTAL	DURADA_AIRE	RETARD	COD_ORIGEN	COD_DESTI	DISTANCIA	VEL_MITJA	RETARDAT	DATA	AEROLINIA
	5180146	1114.0	1091.0	1050.0	SEA	HNL	4308.20	236.931267	True	09092008	Hawaiian Airlines Inc.
	6980183	790.0	634.0	162.0	EWR	HNL	7985.55	755.730288	True	19122008	Continental Air Lines Inc.
	3922427	776.0	346.0	410.0	JFK	SFO	4161.75	721.690724	True	23072008	Delta Air Lines Inc.
	4614554	750.0	733.0	612.0	HNL	SEA	4308.20	352.649399	True	19082008	Hawaiian Airlines Inc.
	4811552	750.0	597.0	388.0	EWR	HNL	7985.55	802.567855	True	02082008	Continental Air Lines Inc.

```
In [33]: #ara obtindrem els n=5 vols més llargs en quant a distància (buscarem distancia, i origen i destinació)
             #aenerarem dues noves columnes per visualitzar el nom dels aeroports que mapejarem d'un arxiu de
                                                                                                                                                 "Suplemental data'
             ap_df.sample(2)
             executed in 68ms, finished 10:08:06 2021-04-14
Out[33]:
                            airport city state country
                                                                                      long
              iata
                Y93 Atlanta Municipal Atlanta
                                                                USA 45.000008 -84.133337
                MIE Delaware County Muncie
                                                      IN
                                                                USA 40.242348 -85.395860
In [34]: #generem nous camps mapejant els codis d'origen i destinació amb la series d'aeroports
             #generem nous camps mapejant els coals à origen i destinació amo la series à deroports
#(ho asignariem directament a la columna en comptes de passar-ho a series, però pels pocs recursos de memòria amb els que
#compto és l'unica manera que no em doni error de memòria)
aer_origen_s = df["COD_ORIGEN"].map(ap_df["airport"])
aer_desti_s = df["COD_DESTI"].map(ap_df["airport"])
             #podem generar tb del mateix mode les ciutats d'origen i destinació
city_origen_s = df["CITY_ORIGEN"] = df["COD_ORIGEN"].map(ap_df["city"])
city_desti_s = df["CITY_DESTI"] = df["COD_DESTI"].map(ap_df["city"])
             #esborrem les columnes de codis d'origen i destinació
             df.drop(columns=["COD_ORIGEN", "COD_DESTI"], inplace=True)
             #generem nous camps mapejant els codis d'origen i destinació amb la series d'aeroports df["AER_ORIGEN"] = aer_origen_s
             df["AER_DESTI"] = aer_desti_s
             #podem generar tb del mateix mode les ciutats d'origen i destinació
             df["CITY_ORIGEN"] = city_origen_s
df["CITY_DESTI"] = city_desti_s
             executed in 1.81s, finished 10:08:10 2021-04-14
In [35]: #com les distàncies son fixes entre aeroports, agrupem per distàncies uniques i seleccionem les n=5 mes grans mes_distants = list(np.sort(df["DISTANCIA"].unique())[-(n+1):-1])
             mes_distants
             executed in 81ms, finished 10:08:10 2021-04-14
Out[35]: [6392.3, 6733.48, 6780.15, 6828.43, 7245.25]
In [36]: #busquem el primer vol que trobem de cada una de les distàncies
series_list = []
for distance in mes_distants:
                  series_list.append(df[df["DISTANCIA"] == distance].iloc[0])
             #creem un nou dataframe i visualitzem els vols amb les n=5 distàncies més llargues
             mes_distants_df = pd.DataFrame(series_list)
mes_distants_df[['DISTANCIA', 'AER_ORIGEN', 'CITY_ORIGEN', 'AER_DESTI', 'CITY_DESTI']]
             executed in 277ms, finished 10:08:13 2021-04-14
Out[36]:
                                                 AER_ORIGEN CITY_ORIGEN
                                                                                                     AER_DESTI CITY_DESTI
```

Minneapolis	Minneapolis-St Paul Intl	Honolulu	Honolulu International	6392.30	438603
Kahului	Kahului	Chicago	Chicago O'Hare International	6733.48	218291
Chicago	Chicago O'Hare International	Kailua/Kona	Kona International At Keahole	6780.15	218265
Honolulu	Honolulu International	Chicago	Chicago O'Hare International	6828.43	218178
Atlanta	William B Hartsfield-Atlanta Intl	Honolulu	Honolulu International	7245.25	305099

In [37]: #busquem els n=5 vols més enraderits
df.nlargest(n, "RETARD", keep='all') executed in 297ms, finished 10:08:17 2021-04-14

Out[37]: DURADA_TOTAL DURADA_AIRE RETARD DISTANCIA VEL MITJA RETARDAT AEROLINIA CITY_ORIGEN CITY DESTI AER ORIGEN AER DESTI 1018798 459 N 437.0 2461.0 6392 30 877 661331 True 03022008 Northwest Airlines Inc. Honolulu Minneapolis Honolulu International Minneapolis-St Paul Intl 2235378 154.0 132.0 2453.0 1496.69 680.313622 True 10042008 Northwest Airlines Inc. Charlotte Minneapolis Charlotte/Douglas Minneapolis-St Paul Intl International 2832617 Southwest Florida 172.0 145.0 1951.0 1746.13 722.536528 True 06052008 Northwest Airlines Inc. Ft. Myers Detroit Detroit Metropolitan-International Wayne County 3387883 72.0 50.0 1707.0 489.24 587.088014 True 20062008 American Eagle Little Rock Dallas-Fort Adams Dallas-Fort Worth Airlines Inc. Worth International 6857047 192.0 1655.0 1808.90 Minneapolis Gen Edw L Logan Intl Minneapolis-St Paul Intl 259.0 565.281242 True 19122008 Northwest Airlines Inc. Boston

DATA

In [38]: #esborrem dataframes i series temporals de suport d'una mida considerable per deixar recursos del ap df, cancel df del aer_origen_s, aer_desti_s, city_origen_s, city_desti_s, any_s, mes_s, dia_s, ap_s executed in 152ms, finished 10:08:19 2021-04-14

3 Exercici

Exporta el data set net i amb les noves columnes a Excel

Ens diu que no és permès un full de més de 1048576 files

Archivo Editar Ver Insertar Formato Herramientas Datos Ventana Ayuda

90	Calibri	· 11	- N	C 5 = 3		% I 🐉 💥		🍜 🗆 • 盭 • 🔠 🖺				
1	→ 🕏	∑ = DUR	ADA TO	'AL								
	Α		С	D	E	F	G	Н	I	J	K	L
1 D	URADA TOTAL D	IRADA AIRE			VEL MITJA	RETARDAT	DATA	AEROLINIA	TY ORIGI	CITY DESTI	AER ORIGEN	AER DESTI
-	113	89		9 857,78	578,2786454889	VERDADERO		AirTran Airways Corporation		Bloomington	William B Hartsfield-Atlanta Intl	Central Illinois Regional
	140	118		3 1522,44	774,1220213854	FALSO	01012008	AirTran Airways Corporation	Atlanta	Boston	William B Hartsfield-Atlanta Intl	Gen Edw L Logan Intl
	134	102	1	4 1522,44	895,5529160569	VERDADERO	01012008	AirTran Airways Corporation	Atlanta	Boston	William B Hartsfield-Atlanta Intl	Gen Edw L Logan Intl
	110	86		1 1145,85	799,4302635859	FALSO	01012008	AirTran Airways Corporation	Atlanta	Buffalo	William B Hartsfield-Atlanta Intl	Buffalo Niagara Intl
	109	89	1	5 1145,85	772,4831377899	VERDADERO	01012008	AirTran Airways Corporation	Atlanta	Buffalo	William B Hartsfield-Atlanta Intl	Buffalo Niagara Intl
	102	85		4 1145,85	808,8353168049	FALSO	01012008	AirTran Airways Corporation	Atlanta	Buffalo	William B Hartsfield-Atlanta Intl	Buffalo Niagara Intl
3	85	70	-1	3 926,98	794,5543127766	FALSO	01012008	AirTran Airways Corporation	Atlanta	Baltimore	William B Hartsfield-Atlanta Intl	Baltimore-Washington Internationa
	92	70		7 926,98	794,5543127766	FALSO	01012008	AirTran Airways Corporation	Atlanta	Baltimore	William B Hartsfield-Atlanta Intl	Baltimore-Washington Internationa
0	90	71		8 926,98	783,3634171093	FALSO	01012008	AirTran Airways Corporation	Atlanta	Baltimore	William B Hartsfield-Atlanta Intl	Baltimore-Washington Internationa
1	99	69		3 926,98	806,0695819289	FALSO	01012008	AirTran Airways Corporation	Atlanta	Baltimore	William B Hartsfield-Atlanta Intl	Baltimore-Washington Internationa
2	98	75		1 926,98	741,584	VERDADERO	01012008	AirTran Airways Corporation	Atlanta	Baltimore	William B Hartsfield-Atlanta Intl	Baltimore-Washington Internationa
3	88	72		9 926,98	772,4833026376		01012008	AirTran Airways Corporation	Atlanta	Baltimore	William B Hartsfield-Atlanta Intl	Baltimore-Washington Internationa
4	93	72		4 849,73				AirTran Airways Corporation		Akron	William B Hartsfield-Atlanta Intl	Akron-Canton Regional
5	94	74		9 849,73	688,9702613912		01012008	AirTran Airways Corporation	Atlanta	Akron	William B Hartsfield-Atlanta Intl	Akron-Canton Regional
5	96	76		1 849,73	670,8394821021			AirTran Airways Corporation	Atlanta	Akron	William B Hartsfield-Atlanta Intl	Akron-Canton Regional
7	74	42		4 416,82	595,4571529977		01012008	AirTran Airways Corporation	Atlanta	Charleston	William B Hartsfield-Atlanta Intl	Charleston AFB/International
В	61	40		8 416,82	625,2299813667			AirTran Airways Corporation	Atlanta	Charleston	William B Hartsfield-Atlanta Intl	Charleston AFB/International
)	55	38		0 416,82				AirTran Airways Corporation		Charleston	William B Hartsfield-Atlanta Intl	Charleston AFB/International
0	49	37		4 365,32	592,4108031761			AirTran Airways Corporation	Atlanta	Charlotte	William B Hartsfield-Atlanta Intl	Charlotte/Douglas International
1	54	39		0 365,32	562,0307898459		01012008	AirTran Airways Corporation		Charlotte	William B Hartsfield-Atlanta Intl	Charlotte/Douglas International
2	56	40		5 365,32	547,9799836689		01012008	AirTran Airways Corporation	Atlanta	Charlotte	William B Hartsfield-Atlanta Intl	Charlotte/Douglas International
3	51	36		.0 365,32	608,8666424725		01012008	AirTran Airways Corporation		Charlotte	William B Hartsfield-Atlanta Intl	Charlotte/Douglas International
4	68	55		6 589,02	642,5672588		01012008	AirTran Airways Corporation		Daytona Beach	William B Hartsfield-Atlanta Intl	Daytona Beach International
5	85	62		2 695,23	672,8032465044			AirTran Airways Corporation		Dayton	William B Hartsfield-Atlanta Intl	James M Cox Dayton Intl
6	84	68		3 695,23	613,4382395957			AirTran Airways Corporation		Dayton	William B Hartsfield-Atlanta Intl	James M <u>Cox Dayton Intl</u>
7	85	67		8 695,23	622,5940254198			AirTran Airways Corporation		Dayton	William B Hartsfield-Atlanta Intl	James M Cox Dayton Intl
8	88	67		2 880,31	788,3373078223			AirTran Airways Corporation		Arlington	William B Hartsfield-Atlanta Intl	Ronald Reagan Washington Nationa
9	86	67		0 880,31	788,3373078223		01012008	AirTran Airways Corporation		Arlington	William B Hartsfield-Atlanta Intl	Ronald Reagan Washington Nationa
0	87	67		2 880,31	788,3373078223		01012008	AirTran Airways Corporation		Arlington	William B Hartsfield-Atlanta Intl	Ronald Reagan Washington Nationa
1	93	68		4 880,31	776,7441230938			AirTran Airways Corporation		Arlington	William B Hartsfield-Atlanta Intl	Ronald Reagan Washington Nationa
2	84	67		4 880,31	788,3373078223			AirTran Airways Corporation		Arlington	William B Hartsfield-Atlanta Intl	Ronald Reagan Washington Nationa
3	215	196		5 1929,6	590,6938804252			AirTran Airways Corporation		Denver	William B Hartsfield-Atlanta Intl	Denver Intl
4	214	194		3 1929,6	596,7835022209			AirTran Airways Corporation		Denver	William B Hartsfield-Atlanta Intl	Denver Intl
5	146	124		3 1178,04	570,0193723746			AirTran Airways Corporation		Dallas-Fort Worth	William B Hartsfield-Atlanta Intl	Dallas-Fort Worth International
5	146	125		0 1178,04	565,4592215706			AirTran Airways Corporation		Dallas-Fort Worth	William B Hartsfield-Atlanta Intl	Dallas-Fort Worth International
7 B	143	124		8 1178,04				AirTran Airways Corporation		Dallas-Fort Worth	William B Hartsfield-Atlanta Intl	Dallas-Fort Worth International
	147	124		3 1178,04	570,0193723746			AirTran Airways Corporation		Dallas-Fort Worth	William B Hartsfield-Atlanta Intl	Dallas-Fort Worth International
9	143	120		7 1178,04		VERDADERO		AirTran Airways Corporation		Dallas-Fort Worth	William B Hartsfield-Atlanta Intl	Dallas-Fort Worth International
L	140 109	125 84		2 1178,04 4 955.95	565,4592215706			AirTran Airways Corporation			William B Hartsfield-Atlanta Intl	Dallas-Fort Worth International
2					682,8214401998			AirTran Airways Corporation		Detroit	William B Hartsfield-Atlanta Intl	Detroit Metropolitan-Wayne Count
-	103	84		0 955,95 3 1198,96	682,8214401998			AirTran Airways Corporation		Detroit	William B Hartsfield-Atlanta Intl	Detroit Metropolitan-Wayne Count
1	115	91			790,5230852077		01012008	AirTran Airways Corporation		Newark	William B Hartsfield-Atlanta Intl	Newark Intl
5	134	96		6 1198,96	749,3499888338			AirTran Airways Corporation		Newark	William B Hartsfield-Atlanta Intl	Newark Intl
5	125 105	98		7 1198,96 5 1198,96	734,0571464288			AirTran Airways Corporation		Newark	William B Hartsfield-Atlanta Intl	Newark Intl
		88 86			817,4727095545		01012008			Newark	William B Hartsfield-Atlanta Intl	Newark Intl
7	106			500,00	032,340330947			AirTran Airways Corporation		A STATE OF THE PARTY OF T	William B Hartsfield-Atlanta Intl	Fort Lauderdale-Hollywood Int'l
	108	93		5 935,03				AirTran Airways Corporation an A / JetBlue Ai / Mesa Airli		Ft. Lauderdale	William B Harshield Atlanta Intl	Fort Lauderdale-Hollywood Int'l